

AAA Backend отчет

Ярослав Волков

Апрель 2026

1 Фреймворк

Я выбрал FastAPI, так как у меня 0 опыта в бэкэнд разработке, а этот фреймворк использовали в примере на лекции + гпт его посоветовал. Я не делал асинхронный код, так как по условию задания обработка запросов и получение эмбедингов происходит на одной машине, то большую часть времени будет занимать именно получение эмбедингов моделью, поэтому асинхронный код не даст большого выигрыша.

2 Метрики

1. Самая важная метрика для инференс сервиса как мне кажется - средняя задержка ответа (latency), т.к. обычно этот сервис будет стоять в какой-то цепочке, которая будет доводить до пользователя результат. Чтобы пользователь не уходил, пока ждет загрузки, нужно прикидывать, сколько займет полная обработка запроса, и лучше еще понимать по частям. Я измерил среднее и некоторые квантили: 50%-ый (медиана), 95% и 99%. Получил такие результаты: Mean: 0.015s, P50: 0.0141s, P95: 0.0206s, P99: 0.0462s
2. Еще я выбрал requests per second и words per seconds (сколько слов модель может в среднем обработать за секунду). Эти метрики важны, чтобы понимать пропускную способность сервиса. У меня получились такие результаты: RPS: 67.133, WPS: 2349.657
3. Еще наверное было бы неплохо посмотреть, сколько ресурсов системы занимает сервис. Т.к. сама модель очень маленькая, скорее всего можно было бы распараллелить инференс и держать несколько моделей одновременно. Но я решил этого не делать.